# Элементы теории трансляции

# Лексический анализ

В основе лексических анализаторов лежат регулярные грамматики.

#### Соглашения:

- для описания лексем будем использовать <u>леволинейную</u> <u>автоматную грамматику</u> без пустых правых частей.

Грамматика G = (T, N, P, S) автоматная *леволинейная*, если каждое правило из P имеет вид

 $A \rightarrow Bt$  либо

 $A \rightarrow t$ , где  $A \in N$ ,  $B \in N$ ,  $t \in T$ .

- анализируемая цепочка заканчивается специальным символом ⊥ - *признаком конца цепочки (символ-терминатор)*.

# Алгоритм разбора по леволинейной грамматике.

первый символ исходной цепочки a<sub>1</sub>a<sub>2</sub>...a<sub>n</sub>⊥ заменяем нетерминалом A, для которого в грамматике есть правило вывода

$$A \rightarrow a_1$$

(производим "свертку" терминала а₁ к нетерминалу А)

(2) пока не считаем признак конца цепочки выполняем следующее: полученный на предыдущем шаге нетерминал **A** и расположенный непосредственно справа от него очередной терминал **a**<sub>i</sub> исходной цепочки заменяем нетерминалом **B**, для которого в грамматике есть правило вывода

$$B \to Aa_i \ (i = 2, 3,..., n)$$

# Алгоритм разбора по леволинейной грамматике.

Если в результате работы алгоритма прочитана вся цепочка, на каждом шаге находилась единственная нужная «свертка», а на последнем шаге произошла свертка к символу S, значит цепочка а<sub>1</sub>а<sub>2</sub>...а<sub>п</sub>⊥ принадлежит языку.

Если на каком-то шаге **не нашлось нужной свертки** или на последнем шаге произошла свертка к символу, **отличному от S**, значит цепочка  $a_1a_2...a_n\bot$  **не** принадлежит языку.

Если на каком-то шаге нашлось более одной подходящей свертки, значит разбор по заданной грамматике недетерминированный.

# Диаграммы состояний (ДС)


**Диаграмма состояний (ДС)** - неупорядоченный ориентированный помеченный граф, который строится следующим образом:

- (1) строим вершины графа, помеченные нетерминалами грамматики (для каждого нетерминала одну вершину), и еще одну вершину, помеченную символом, отличным от нетерминальных (например, Н). Эти вершины называются состояниями. Н начальное состояние.
- (2) соединяем эти состояния дугами по следующим правилам:
  - а) для каждого правила вида W → t соединяем дугой состояния H и W (от H к W) и помечаем дугу символом t;
  - б) для каждого правила вида W → Vt соединяем дугой состояния V и W (от V к W) и помечаем дугу символом t.

Диаграмма состояний для грамматики  $G_ex = (\{a, b, \bot\}, \{S, A, B, C\}, P, S), где$ 

P: 
$$S \rightarrow C \perp$$
  
 $C \rightarrow Ab \mid Ba$   
 $A \rightarrow a \mid Ca$   
 $B \rightarrow b \mid Cb$ 

будет выглядеть так:



$$L(G) = \{ ([ab | ba])^n \perp | n >= 1 \}$$

# Алгоритм разбора по диаграмме состояний

- (1) объявляем текущим состояние Н;
- (2) пока не считаем признак конца цепочки выполняем следующее: считываем очередной символ исходной цепочки и переходим из текущего состояния в другое состояние по дуге, помеченной этим символом. Состояние, в которое мы при этом попадаем, становится текущим.
- Если в результате работы алгоритма прочитана вся цепочка, на каждом шаге находилась единственная дуга, помеченная очередным символом анализируемой цепочки, а последний переход произошел в состояние S, значит исходная цепочка принадлежит языку.
- Если на каком-то шаге не нашлось дуги, выходящей из текущего состояния и помеченной очередным анализируемым символом или на последнем шаге произошел переход в состояние, отличное от S, значит исходная цепочка не принадлежит языку.
- Если на каком-то шаге работы алгоритма нашлось несколько дуг, выходящих из текущего состояния, помеченных анализируемым символом, но ведущих в разные состояния, значит разбор по заданной грамматике недетерминированный.

# Диаграммы состояний для праволинейных грамматик

(1) строим вершины графа, помеченные нетерминалами грамматики, и еще одну вершину, помеченную символом, отличным от нетерминальных (например, F). Эти вершины называются *состояниями*. S - начальное состояние.


F – заключительное состояние.

- (2) соединяем эти состояния дугами по следующим правилам:
  - a) для каждого правила вида W → t соединяем дугой состояния F и W (от W к F) и помечаем дугу символом t;
  - б) для каждого правила вида W → t V соединяем дугой состояния V и W (от W к V) и помечаем дугу символом t;

Диаграмма состояний для грамматики  $G_{ex2} = (\{0, 1, \bot\}, \{S, B, C\}, P, S), где$ 

 $S \rightarrow 0B$ будет выглядеть так:  $B \rightarrow 1B \mid 1C \mid \bot$ 

$$L(G) = \{ 0 \ 1^n \perp | \ n \ge 0 \}$$



# Теорема

Имея ДС, построенную по любой регулярной грамматике, можно по ней восстановить как леволинейную, так и эквивалентную ей праволинейную регулярную грамматику.

# Алгоритм построения праволинейной грамматики $G_{right}$ по ДС, построенной по леволинейной грамматике $G_{left}$ .

- Нетерминалами  $G_{right}$  будут все состояния из ДС, кроме S.
- Если в ДС есть исходящие дуги из S, то вводим в ДС новое заключительное состояние S', в которое из S ведет дуга, помеченная признаком конца ⊥.
- Каждой дуге из состояния V в заключительное состояние S (или S'), помеченной символом t (  $\bot$  ) ставится в соответствие правило  $V \to t$  (  $V \to \bot$ ).
- Каждой дуге из состояния V в состояние W, помеченной символом t, ставится в соответствие правило  $V \to tW$ .
- Начальное состояние *H* объявляется начальным символом грамматики.

# Алгоритм построения леволинейной грамматики $G_{rleft}$ по ДС, построенной по праволинейной грамматике $G_{right}$

- Нетерминалами  $G_{left}$  будут все состояния из ДС для  $G_{right}$ , кроме S.
- Каждой дуге из состояния S в состояние W, помеченной символом t, ставится в соответствие правило W  $\to$  t. Если в ДС есть входящие дуги в S, то в  $G_{left}$  добавляется также и правило W  $\to$  St.
- Каждой дуге из состояния V в состояние W, помеченной символом t, ставится в соответствие правило  $W \to Vt$ .
- Заключительное состояние F объявляется начальным символом грамматики.

# Соглашения для работы с диаграммами состояний

- а) Если из одного состояния в другое выходит несколько дуг, помеченных разными символами, то изображается одна дуга, помеченная всеми этими символами.
- b) Непомеченная никакими символами дуга соответствует переходу при любом символе, кроме тех, которыми помечены другие дуги, выходящие из этого состояния.
- с) Вводится дополнительное состояние ошибки (ER); переход в это состояние означает, что исходная цепочка языку не принадлежит.

# Конечный автомат (КА)

**Конечный автомат (КА)** - это пятерка (K, T,  $\delta$  , H, S), где

К - конечное множество состояний;

Т - конечное множество допустимых входных символов;

 $\delta$  - отображение (функция переходов) множества  $K \times T \to K$ , определяющее поведение автомата;

 $H \in K$  - начальное состояние;

 $S \in K$  - заключительное состояние (либо конечное множество заключительных состояний, но для грамматик — одно!).

 $\delta$  (A, t) = B означает, что из состояния A по входному символу t происходит переход в состояние B.

Конечный автомат **допускает цепочку**  $a_1a_2...a_n$ , если  $\delta(H, a_1) = A_1; \ \delta(A_1, a_2) = A_2; \ ...; \ \delta(A_{n-2}, a_{n-1}) = A_{n-1}; \ \delta(A_{n-1}, a_n) = S,$  где  $a_i \in T$ ,  $A_j \in K$ , j = 1, 2, ..., n-1; i = 1, 2, ..., n; H - начальное состояние, S - одно из заключительных состояний.

Множество цепочек, допускаемых конечным автоматом, составляет определяемый им *язык*.

### Анализатор для регулярной грамматики G\_ex.

```
char c;
void gc() {cin>>c;}
```

```
bool scan G ( ) {
    enum state { H, A, B, C, S, ER };
    state CS; // CS - текущее состояние
    CS = H;
    do { gc ();
            switch (CS) {
                if (c == 'a') { CS = A; }
        case H:
                    else if (c == 'b') \{ CS = B; \}
                    else CS = ER;
                      break;
        case A: if (c == 'b') \{ CS = C; \}
                else CS = ER;
                    break;
                    if (c == 'a') \{ CS = C; \}
        case B:
                    else CS = ER;
                       break;
            case C: if (c == 'a') \{ CS = A_i \}
                    else if (c == 'b') \{ CS = B; \}
                    else if (c == '\bot') CS = S;
                        else CS = ER;
                     break;
        } while (CS != S && CS != ER);
    if (CS == ER) return false;
    else return true;
```

# О недетерминированном разборе

При анализе по ДС для регулярной грамматики может оказаться, что из одного состояния выходит несколько дуг, ведущих в разные состояния, но помеченных одним и тем же символом.

Для леволинейных грамматик эта ситуация возникает, когда в правилах вывода есть совпадающие правые части.

Для праволинейных грамматик аналогичная ситуация возникает, когда альтернативы вывода из одного нетерминала грамматики начинаются одинаковыми терминальными символами.

# **Недетерминированный конечный автомат (НКА)** – это пятерка ( K, T, $\delta$ , H, S ) , где

- К конечное множество состояний;
- Т конечное множество допустимых входных символов;
- $\delta$  отображение множества  $K \times T$  в множество подмножеств K;
- Н ⊂ К конечное множество начальных состояний (у нас одно!);
- S ⊂ K конечное множество заключительных состояний (у нас одно!).

 $\delta$  (A,t) = {B1,B2,...,Bn} означает, что из состояния A по входному символу t можно осуществить переход в любое из состояний Bi, i = 1, 2, ...,n.

### Алгоритм построения детерминированного КА по НКА

**Вход**:  $M = (K, T, \delta, H, S) - HKA$ .

**Выход**: M1 = (K1, T, δ1, H1, S1) - ДКА, допускающий тот же язык, что и автомат М. **Метод**:

Строим отображение  $\delta 1$  (K1 × T  $\rightarrow$  K1) по  $\delta$ , начиная с состояния H.

- **1.** δ1 для H ⊂ K1 строим т.о.:
  - если в НКА переход из Н по какому-то символу был детерминированным, переносим соответствующие отображение в результирующий КА. Состояния, появляющиеся в правой части отображений δ1 принадлежат К1;
  - если же в НКА переход из H по какому-то символу t был недетерминированным, то в КА включаем отображения  $\delta 1$  по правилу:  $\delta 1$  (H, t) =  $\underline{A1A2...An}$ , где  $Ai \subset K$ , и в НКА есть F (H, t) = Ai для всех 1 <= i <= n.

Состояние  $A1A2...An \subset K1$ .

**2.** Для всех состояний, появившихся в правой части отображений  $\delta 1$  результирующего КА, определяем отображения  $\delta 1$  т.о.:  $\delta 1 (\underline{A1A2...An}, t) = \underline{B1B2...Bm}, \quad \text{где для каждого} \quad 1 <= j <= m \quad \text{в} \quad \text{НКА}$  существует  $\delta (Ai, t) = Bj \quad \text{для каких-либо} \quad 1 <= i <= n.$ 

Заключительными состояниями построенного детерминированного КА являются все состояния, содержащие  $S \subset K$  в своем имени. Для написания грамматики по КА все эти состояния **необходимо свести к** одному заключительному состоянию  $S1 \subset K1$  с помощью символа  $\bot$ .

# Пример работы алгоритма преобразования НКА в КА

Задан НКА  $M = ( \{ H, A, B, S \}, \{ 0, 1 \}, \delta, \{ H \}, \{ S \} ),$  где

Функции переходов КА, построенные по НКА в соответствии с предложенным алгоритмом.

$$δ1(H, 1) = B$$
  
 $δ1(B, 0) = A$   
 $δ1(A, 1) = BS$   
 $δ1(BS, 0) = A$ 

Заключительным состоянием построенного детерминированного КА является состояние <u>BS.</u>

Таким образом, M1 = ({H, B, A, BS}, {0, 1},  $\delta$ 1, H, BS).

# Комментарии и проблемы

- Алгоритм детерминизации конечного автомата был впервые предложен Эдвардом Форестом Муром.
- Быстрый рост размера автомата в результате детерминизации. (экспоненциальный взрыв)
- Избыточность детерминированного автомата.

# Комментарии

- Можно ли описать автоматный язык без использования автоматов?
- Да, ведь он не зря называется регулярным.
- Регулярные выражения зачастую используются в текстовых редакторах и не только. Многие из современных языков программирования включают в себя явный механизм разбора регулярных выражений.

# Регулярные выражения

Регулярные выражения над алфавитом A={a1, a2, ..., an} — это формулы, которые определяются над множеством констант {0, 1, a1, a2, ..., an} и множеством операций, состоящим из двухместных операций "x", "+" и одноместной операции "\*".

Регулярным выражением называется всякая формула, удовлетворяющая требованиям:

- 1. каждая константа регулярное выражение;
- 2. если формулы R1 и R2 являются регулярными выражениями, то формулы (R1xR2), (R1+R2), (R1\*) также являются регулярными выражениями.

```
Приоритеты: *
```

X

+

# Регулярные выражения

Значением регулярного выражения R является формальный язык L(R), который определяется по правилам:

- 1.  $L(0) = \emptyset$
- 2.  $L(1) = \{\epsilon\}$
- 3.  $L(a_i) = \{a_i\}, 1 <= i <= n$
- 4. L(R1xR2) = L(R1)L(R2) (конкатенация)
- 5. L(R1+R2) = L(R1) ∪ L(R2) (объединение)
- 6.  $L(R1^*) = L^*(R1)$  (итерация)

Язык называется регулярным, если он является значением некоторого регулярного выражения.

# Теорема Клини

Формальный язык является автоматным тогда и только тогда, когда он является регулярным.


# Задачи лексического анализа

- 1. выделить в исходном тексте цепочку символов, представляющую лексему, и проверить правильность ее записи;
- 2. удалить пробельные литеры и комментарии;
- 3. преобразовать цепочку символов, представляющих лексему, в пару:

```
(тип_лексемы, указатель_на_информацию_о_ней);
```

4. зафиксировать в специальных таблицах для хранения разных типов лексем факт появления соответствующих лексем в анализируемом тексте.

Чтобы решить эту задачу, опираясь на способ анализа с помощью ДС, на дугах вводится дополнительные пометки-действия. Теперь каждая дуга в ДС может выглядеть так:



# Лексический анализ языков программирования

Принято выделять следующие типы лексем: идентификаторы, служебные слова, константы и ограничители.

Каждой лексеме сопоставляется пара:

```
( тип_лексемы, указатель_на_информацию_о_ней ).
```

Таким образом, лексический анализатор - это транслятор, входом которого служит цепочка символов, представляющих исходную программу, а выходом - последовательность лексем.

Лексемы перечисленных выше типов можно описать с помощью регулярных грамматик. Например,

идентификатор (I):

$$I \rightarrow a | b | ... | z | Ia | Ib | ... | Iz | I0 | I1 | ... | I9$$

целое без знака (N):

$$N \rightarrow 0 | 1 | ... | 9 | N0 | N1 | ... | N9$$

# Описание модельного языка

```
P \rightarrow program D1; B \perp
D1 \rightarrow var D \{, D\}
\mathsf{D} \ \rightarrow \ \mathsf{I} \ \{ \ , \ \mathsf{I} \ \} : [ \ \mathsf{int} \ | \ \mathsf{bool} \ ]
B \rightarrow begin S \{; S\} end
S \rightarrow I := E \mid \text{if } E \text{ then } S \text{ else } S \mid \text{while } E \text{ do } S \mid B \mid \text{read } (I) \mid \text{write } (E)
\mathsf{E} \rightarrow \mathsf{E1}[=|<|>|<=|>=|!=]\mathsf{E1}|\mathsf{E1}
E1 \rightarrow T\{[+|-|or]T\}
T \rightarrow F\{[*|/|and]F\}
F \rightarrow I | N | L | not F | (E)
L \rightarrow true \mid false
I \rightarrow a | b | ... | z | Ia | Ib | ... | Iz | I0 | I1 | ... | I9
N \rightarrow 0 | 1 | ... | 9 | N0 | N1 | ... | N9
```

#### Замечания:

- запись вида  $\{\alpha\}$  означает итерацию цепочки  $\alpha$ , т.е. в порождаемой цепочке в этом месте может находиться либо  $\epsilon$ , либо  $\alpha$ , либо  $\alpha\alpha$ , либо  $\alpha\alpha$  и т.д.
- запись вида [  $\alpha$  |  $\beta$  ] означает, что в порождаемой цепочке в этом месте может находиться либо  $\alpha$ , либо  $\beta$ .
- Р цель грамматики; символ ⊥ маркер конца текста программы.

# Контекстные условия.

- Любое имя, используемое в программе, должно быть описано и только один раз.
- В операторе присваивания типы переменной и выражения должны совпадать.
- В условном операторе и в операторе цикла в качестве условия возможно только логическое выражение.
- Операнды операции отношения должны быть целочисленными.
- Тип выражения и совместимость типов операндов в выражении определяются по обычным правилам; старшинство операций задано синтаксисом.
- В любом месте программы, кроме идентификаторов, служебных слов и чисел, может находиться произвольное число пробелов и комментариев вида **{** < любые символы, кроме '}', '{' и '⊥' > **}**.
- Program, var, int, bool, begin, end, if, then, else, while, do, true, false, read и write служебные слова (их нельзя переопределять).
- Используется паскалевское правило о разделителях между идентификаторами, числами и служебными словами.

# Представление лексем

enum type\_of\_lex {

```
LEX_NULL, /*0*/
LEX_AND, LEX_BEGIN, ... LEX_WRITE, /*18*/
LEX_FIN, /*19*/
LEX_SEMICOLON, LEX_COMMA, ... LEX_GEQ, /*35*/
LEX_NUM, /*36*/
LEX_ID, /*37*/
POLIZ_LABEL, /*38*/
POLIZ_ADDRESS, /*39*/
POLIZ_GO, /*40*/
POLIZ_FGO }; /*41*/
```

Содержательно внутреннее представление лексем - это пара (тип\_лексемы, значение\_лексемы).

Значение лексемы - это номер строки в таблице лексем соответствующего класса, содержащей информацию о лексеме, или непосредственное значение, например, в случае целых чисел.

# Соглашение об используемых таблицах лексем:

**TW** - таблица служебных слов М-языка;

**TD** - таблица ограничителей М-языка;

**TID** - таблица идентификаторов анализируемой программы;

### Класс Lex

```
class Lex {
    type_of_lex t_lex;
    int v lex;
public:
    Lex (type of lex t = LEX NULL, int v = 0) {
          t lex = t;
         v lex = v;
    type_of_lex get_type ( ) {
          return t lex;
    int get value ( ) {
          return v lex;
    friend ostream& operator << (ostream & s, Lex 1 ) {
          s << '(' << l.t lex << ',' << l.v lex << ");";
          return s;
```

#### Класс Ident

```
class Ident {
           char *name;
           bool declare;
           type of lex type;
           bool assign;
           int value;
    public:
           Ident ( ) { declare = false; assign = false; }
           char *get name ( ) { return name; }
           void put name ( const char * n ) {
                  name = new char [ strlen (n) + 1];
                  strcpy ( name, n );
            }
           bool get declare ( ) { return declare; }
           void put declare ( ) { declare = true; }
           type of lex get_type ( ) { return type; }
           void put type ( kind of lex t ) { type = t; }
           bool get assign ( ) { return assign; }
           void put assign ( ) { assign = true; }
           int get value ( ) { return value; }
           void put value ( int v ) { value = v; }
};
```

## Класс tabl\_ident

```
class tabl ident{
    ident *p;
    int size;
    int top;
public:
    tabl ident ( int max size ) {
           p = new ident [ size = max size ];
           top = 1;
    }
    ~tabl ident ( ) { delete [ ] p; }
    ident & operator [ ] ( int  k ) { return p [ k ]; }
    int put (const char * buf);
};
int tabl ident::put(const char * buf) {
           for (int j = 1; j < top; j++)
                  if (!strcmp( buf,p[j].get_name())) return j;
           p [ top ].put name ( buf );
           top++;
           return top - 1;
```

#### Класс Scanner

```
class Scanner {
     enum state { H, IDENT, NUMB, COM, ALE, DELIM, NEQ };
     static char* TW [ ];
     static type of lex words [ ];
     static char * TD [ ];
     static type_of_lex dlms [ ];
     state CS;
     FILE *fp;
     char c;
     char buf [ 80 ];
     int buf top;
     void clear ( );
     void add ( );
     int look (const char * buf, char ** list);
     void gc ( ) { c = fgetc ( fp ); }
 public:
     Scanner (const char * program);
     Lex get_lex ();
};
```


#### Класс Scanner

```
void Scanner::clear ( ) {
      buf top = 0;
      for (int j = 0; j < 80; j++)
              buf [ j ] = ' \setminus 0';
}
void Scanner::add ( ) {
      buf [ buf_top ++ ] = c;
     Scanner::look (const char * buf, char * * list) {
int
      int i = 0;
      while (list [ i ]) {
          if (! strcmp (buf, list [ i ] ) )
                   return i;
          i++;
      return 0;
 Scanner::Scanner (const char * program) {
      fp = fopen ( program, "r" );
      CS = H;
      clear();
```

# Таблицы лексем для М-языка

```
char * Scanner:: TW [] =
 { NULL, "and", "begin", "bool", "do", "else", "end",
        1 2 3 4 5
  "if","false","int","not","or","program","read",
// 7 8 9 10 11 12
                                    13
    "then","true","var","while","write" };
// 14 15 16 17 18
char * Scanner:: TD [] = {NULL, ";", "@", ",", ":", ":=", "(", ")",
                        // 1 2 3 4 5 6 7
                       "=","<", ">", "+", "-", "*", "/", "<=", ">="};
                        // 8 9 10 11 12 13 14 15
```

tabl ident **TID** (100);



```
Lex Scanner::get lex ( ) {
    int d, j;
    CS = H;
    do { gc ();
           switch(CS) {
           case H:
                  if(c==' '||c=='\n'||c=='\r'||c =='\t')
                 else
                  if(isalpha(c)){clear(); add(); CS = IDENT;}
                 else
                  if (isdigit(c))\{d = c - '0'; CS = NUMB;\}
                 else
                  if ( c == '{' ) { CS = COM; }
                 else
                  if ( c == ':' || c == '<' || c == '>') {
                        clear(); add(); CS = ALE; }
                 else
                  if (c == '@') return Lex (LEX FIN);
                 else
                  if(c=='!')\{clear(); add(); CS = NEQ;\}
                 else CS = DELIM;
                 break;
```

```
case IDENT:
      if ( isalpha(c) || isdigit(c) ) {
            add(); }
      else
      if (j = look (buf, TW))
            return Lex (words[ j ], j);
      else {
            j = TID.put (buf);
            return Lex (LEX_ID, j);
      break;
case NUMB:
      if ( isdigit (c) ) {
            d = d * 10 + (c - '0');
      else
            return Lex ( LEX NUM, d);
      break;
case COM:
      if ( c == '}' ) { CS = H; }
      else
      if (c == '@' | c == '{' ) throw c;
      break;
```

```
case ALE:
          if (c == '=') \{ add();
                       j = look (buf, TD);
                       return Lex ( dlms [ j ], j);
          else { j = look (buf, TD);
                return Lex ( dlms [ j ], j ); }
          break;
   case NEQ:
          if ( c == '=') {
                add(); j = look (buf, TD);
                return Lex ( LEX NEQ, j ); }
          else throw '!';
          break;
   case DELIM:
          clear(); add();
          if (j = look(buf, TD)) {
                 return Lex ( dlms [ j ], j ); }
          else throw c;
          break;
    } //end switch
} while ( true );
```