Синтаксический анализ

Задачи синтаксического анализа

- **установить, имеет ли цепочка лексем структуру, заданную синтаксисом языка, т.е. решить задачу разбора по заданной грамматике,**
- **зафиксировать эту структуру.**

Для описания синтаксиса языков программирования используются КС-грамматики, правила которых имеют вид

$A \to \alpha,$ где $A \in N, \quad \alpha \in (T \cup N)^*$.

Для разных подклассов КС-грамматик существуют достаточно эффективные алгоритмы разбора.

Некоторые общие алгоритмы анализа по КС-грамматикам:

- синтаксический анализ с возвратами
  (время работы **экспоненциально** зависит от длины цепочки);
- алгоритм Кока-Янгера-Касами
  (для разбора цепочек длины n требуется время $\mathbf{cn^3}$);
- алгоритм Эрли (для разбора цепочек длины n требуется время $\mathbf{cn^3}$).

Эти (и подобные им по времени работы) алгоритмы практически неприемлемы.

Алгоритмы анализа, расходующие на обработку входной цепочки линейное время, **применимы** только к некоторым **подклассам** КС-грамматик.

Применимость синтаксических анализаторов

Каждый метод синтаксического анализа основан на своей технике построения дерева вывода и предполагает свой способ построения по грамматике программы-анализатора, которая будет осуществлять разбор цепочек.

Корректный анализатор завершает свою работу для любой входной цепочки и выдает верный ответ о принадлежности цепочки языку.

Анализатор ***некорректен***, если:

- не распознает хотя бы одну цепочку, принадлежащую языку;
- распознает хотя бы одну цепочку, языку не принадлежащую;
- зацикливается на какой-либо цепочке.

Метод анализа ***применим*** к данной грамматике, если анализатор, построенный в соответствии с этим методом, **корректен** и строит все возможные выводы цепочек в данной грамматике.

Метод рекурсивного спуска (РС-метод)

Пусть дана грамматика **G_pc = ({ a,b,c, ⊥ }, { S,A,B }, P, S),** где

P: $S \to AB\perp$ $\qquad L(G) = \{ c^n abc^m a\perp \mid n,m >= 0 \}$

$A \to a \mid cA$

$B \to bA$

и надо определить, принадлежит ли цепочка **caba** языку L(G).

Построим вывод этой цепочки:

$S \to AB\perp \to cAB\perp \to caB\perp \to cabA\perp \to caba\perp$

Следовательно, цепочка принадлежит языку L(G).

Последовательность применений правил вывода эквивалентна построению дерева разбора методом "сверху вниз", а метод рекурсивного спуска фактически реализует этот способ разбора.

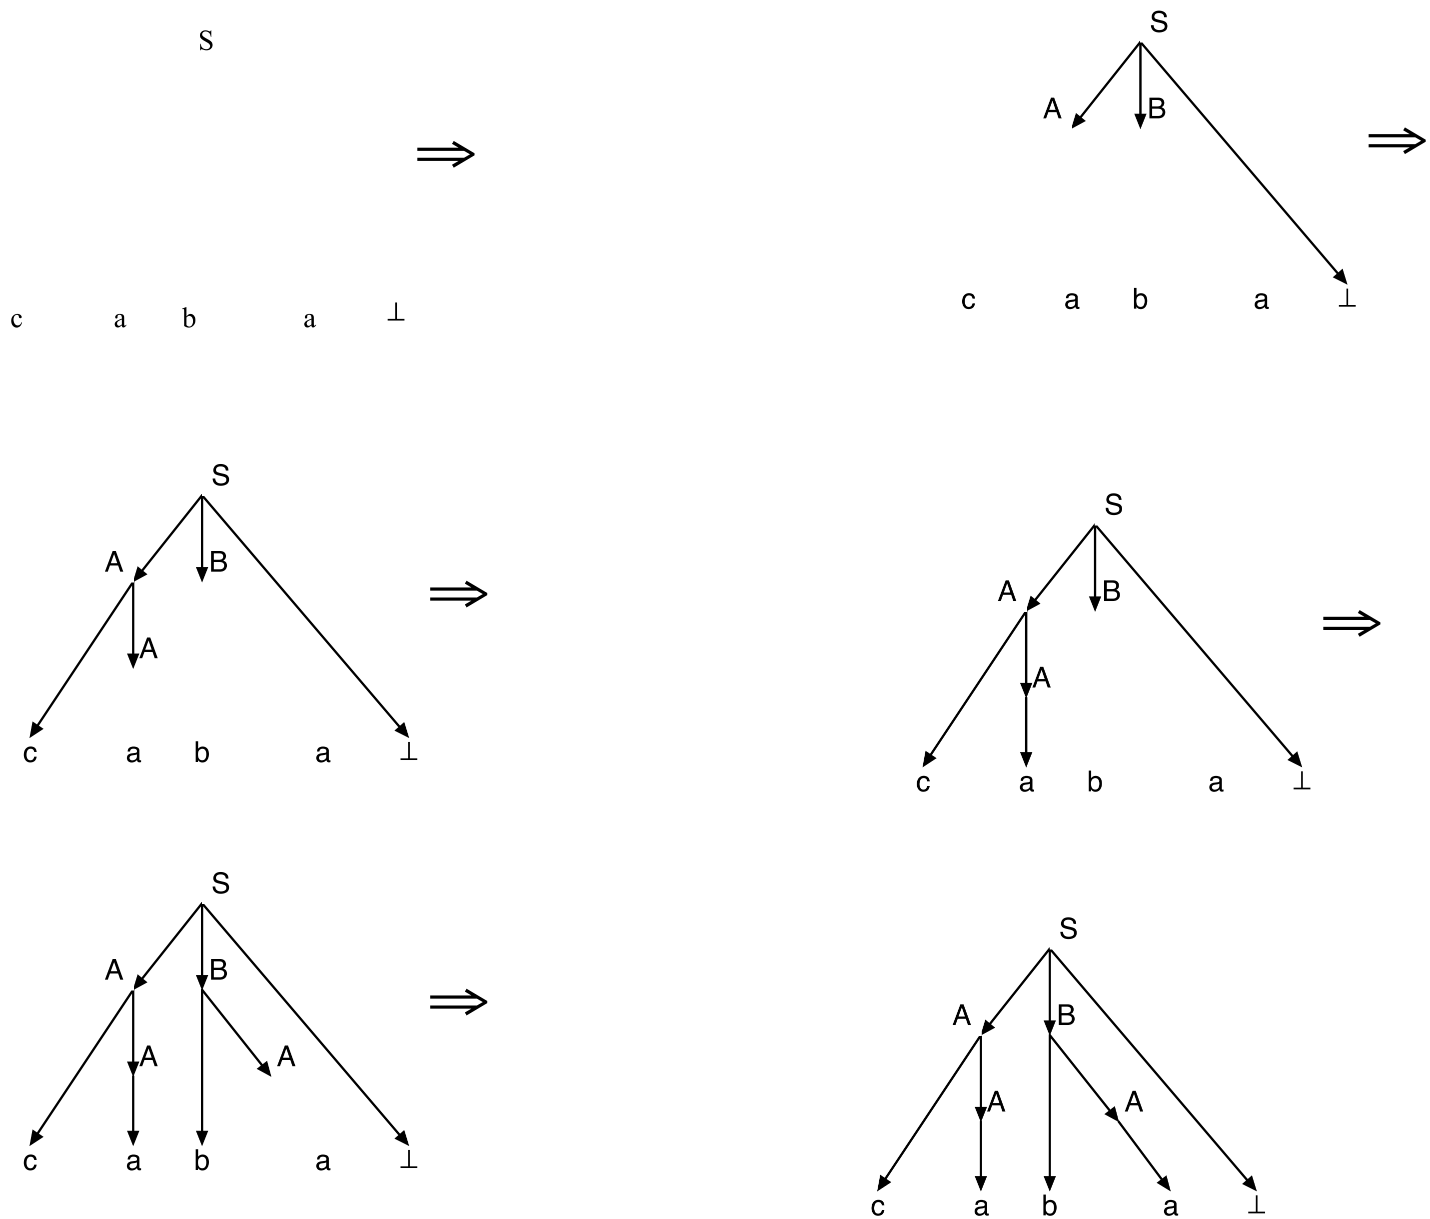
S
c a b a ⊥
S
A B
c a b a ⊥
S
A B
A
c a b a ⊥
S
A B
A
c a b a ⊥
S
A B
A A
c a b a ⊥
S
A B
A A
c a b a ⊥

Метод рекурсивного спуска (РС-метод)

- Для **каждого нетерминала** грамматики создается своя процедура, носящая **его имя**; задача этой процедуры - начиная с указанного места исходной цепочки, найти подцепочку, которая выводится из этого нетерминала.

- Если такую подцепочку считать не удается, то процедура завершает свою работу, сигнализируя об ошибке, что означает, что цепочка не принадлежит языку, и останавливая разбор.

- Если подцепочку удалось найти, то работа процедуры считается нормально завершенной и осуществляется возврат в точку вызова.

- Тело каждой такой процедуры пишется непосредственно по правилам вывода из соответствующего нетерминала.

- Текущая анализируемая лексема входной цепочки должны быть уже прочитана и доступна в процедуре, именно по ней осуществляется выбор нужной альтернативы.

- Для каждой альтернативы из правой части правила вывода осуществляется поиск подцепочки, выводимой из этой альтернативы. При этом:
  - терминалы проверяются в самой процедуре, и
    в случае удачной проверки считывается очередная лексема;
  - нетерминалам соответствуют вызовы процедур,
    носящих их имена.

Метод рекурсивного спуска

Работа системы процедур, построенных в соответствии с РС-методом, начинается с главной функции *main* ( ), которая:

- считывает первый символ исходной цепочки (заданной во входном потоке *stdin*),
- затем вызывает процедуру *S* ( ), которая проверяет, выводится ли входная цепочка из начального символа *S* (в общем случае это делается с участием других процедур, которые, в свою очередь, рекурсивно могут вызывать и саму *S* ( ) для анализа фрагментов исходной цепочки).

Считаем, что в конце любой анализируемой цепочки всегда присутствует символ $\perp$ (признак конца цепочки). На практике этим признаком может быть ситуация «конец файла» или маркер «конец строки».

В задачу *main* ( ) входит также распознавание символа $\perp$.

Можно считать, что *main* ( ) соответствует добавленному в грамматику правилу $M \to S\perp$, где M — новый начальный символ.

Реализация РС-метода для грамматики G_pc.

```
int c;
void A ( );

void B ( );
void gc ( ) {
   cin >> c;
}

void S ( ) {
    A ( );

    B ( );

    if (c  !=  '⊥')    throw c;
}
```

```
void A ( ) {
    if (c == 'a')   gc ();

    else
    if (c == 'c') { gc (); A ( );  }
    else   throw c;
}

void B ( ) {
        if (c == 'b'){gc();A( ); }

        else    throw c;

        }
```

```
int main ( ) {
   try { gc ( );
         S ( );
         cout << "SUCCESS !!!" << endl;
         return 0;
    }
   catch ( int c ) {
         cout << "ERROR on lexeme" << c << endl;
         return 1;
   }
}
```

Достаточное условие применимости РС-метода

Метод рекурсивного спуска применим к КС-грамматике, если каждая ее группа правил вывода из A имеет один из следующих видов:

1. либо $A \to \alpha$, где $\alpha \in (T \cup N)^*$ и это единственное правило вывода для этого нетерминала;
2. либо $A \to a_1\alpha_1 \mid a_2\alpha_2 \mid \ldots \mid a_n\alpha_n$,
   где $ai \in T$ для всех $i = 1, 2, \ldots, n$; $a_i \neq a_j$ для $i \neq j$; $\alpha_i \in (T \cup N)^*$,
3. либо $A \to a_1\alpha_1 \mid a_2\alpha_2 \mid \ldots \mid a_n\alpha_n \mid \varepsilon$,
   где $a_i \in T$ для всех $i = 1, 2, \ldots, n$; $a_i \neq a_j$ для $i \neq j$; $\alpha_i \in (T \cup N)^*$,
   и **first (A) $\cap$ follow (A) = $\varnothing$.**

Множество first (A) - это множество терминальных символов, которыми начинаются цепочки, выводимые из A в грамматике G = (T, N, P, S):

$$\textbf{first}\ (A) = \{\, a \in T \mid A \Rightarrow a\alpha',\ \text{где}\ A \in N,\ \alpha' \in (T \cup N)^* \,\}.$$

Множество follow (A) - это множество терминальных символов, которые следуют за цепочками, выводимыми из A в грамматике G = (T, N, P, S),

$$\textbf{follow}\ (A) = \{\, a \in T \mid S \Rightarrow \alpha A \beta,\ \beta \Rightarrow a\,\gamma,\ A \in N,\ \alpha, \beta, \gamma \in (T \cup N)^* \}.$$

Если все правила вывода заданной КС-грамматики G удовлетворяют указанному условию, то РС-метод к ней применим, при этом грамматика G называется грамматикой **канонического вида** для РС-метода.

О применимости РС-метода

Сформулированное выше условие не является необходимым.

Метод рекурсивного спуска представляет собой одну из возможных реализаций нисходящего анализа с прогнозируемым выбором альтернатив.

Прогнозируемый выбор означает, что **по грамматике** можно заранее **предсказать**, какую альтернативу нужно будет выбрать на очередном шаге вывода в соответствии с текущим символом (т.е. первым символом из еще не прочитанной части входной цепочки).

РС-метод **не**применим, если такой выбор **не**однозначен.

Например, для грамматики

G: $S \to A \mid B$
$A \to aA \mid d$
$B \to aB \mid b$

РС-метод неприменим, поскольку, если первый прочитанный символ есть ‘a’, то выбор альтернативы правила вывода из S неоднозначен.

РС-метод неприменим к неоднозначным грамматикам, так как на каком-либо шаге анализа выбор альтернативы вывода обязательно будет неоднозначным.

Критерий применимости РС-метода

Пусть G — КС-грамматика.

РС-метод применим к G, тогда и только тогда, когда для любой пары альтернатив $X \to \alpha \mid \beta$ выполняются следующие условия:

1. $first(\alpha) \cap first(\beta) = \varnothing$;
2. справедливо не более чем одно из двух соотношений:
   $\alpha \Rightarrow \varepsilon$, $\beta \Rightarrow \varepsilon$;
3. если $\beta \Rightarrow \varepsilon$, то $first(\alpha) \cap follow(X) = \varnothing$.

Множество **first** (α) — это множество терминальных символов, которыми начинаются цепочки, выводимые из цепочки α в грамматике G = (T, N, P, S), т. е.

$$\mathbf{first}(\alpha) = \{ \mathbf{a} \in \mathbf{T} \mid \alpha \Rightarrow \mathbf{a}\alpha', \text{ где } \alpha \in (\mathbf{T} \cup \mathbf{N})^+, \ \alpha' \in (\mathbf{T} \cup \mathbf{N})^* \}.$$

Множество **follow(A)** — это множество терминальных символов, которые могут появляться в сентенциальных формах грамматики G = (T, N, P, S) непосредственно справа от A (или от цепочек, выводимых из A) , т.е.

$$\mathbf{follow}(\mathbf{A}) = \{ \mathbf{a} \in \mathbf{T} \mid \mathbf{S} \Rightarrow \alpha\mathbf{A}\beta, \ \beta \Rightarrow \mathbf{a}\gamma, \ \mathbf{A} \in \mathbf{N}, \ \alpha, \beta, \gamma \in (\mathbf{T} \cup \mathbf{N})^* \}.$$

Итерационные правила в КС-грамматиках

Наличие в грамматике итерационных правил вида

$\mathbf{A} \rightarrow \alpha\ \mathbf{\{}\ \beta\ \mathbf{\}}\ \gamma$, где $A \in N$, $\beta \in (T \cup N)^+$, $\alpha, \gamma \in (T \cup N)^*$

скрывает правила с ε-альтернативой.

Чтобы проверить грамматику с итерационными правилами на применимость РС-метода, надо заменить итерационные правила обычными правилами следующим образом: каждое правило вида

$A \rightarrow \alpha\ \{\ \beta\ \}\ \gamma$ заменить на два правила $A \rightarrow \alpha\ W\ \gamma$

$W \rightarrow \beta W \mid \varepsilon$,

(где W – новый нетерминал, ранее не принадлежавший множеству N),

а затем поверить критерий применимости РС-метода.

Процедура по РС-методу для итерационных правил пишется по следующей схеме:

```
void A () {
        < анализ цепочки α >;
        while (<текущий_символ_входной_цепочки == первый_символ_ β >)
                < анализ цепочки β >;
        < анализ цепочки γ >;
}
```

Преобразования грамматик

Проблема возможности построения грамматики, к которой применим метод рекурсивного спуска, эквивалентной грамматике, не удовлетворяющей критерию применимости РС-метода, является **алгоритмически неразрешимой проблемой.**

1) Если в грамматике есть нетерминалы, правила вывода которых **леворекурсивны**, т.е. имеют вид

$A \to A\alpha_1 \mid \ldots \mid A\alpha_n \mid \beta_1 \mid \ldots \mid \beta_m,$ // $\boldsymbol{A \to A\alpha \mid \beta}$

где $\alpha_i \in (T \cup N)^+$, $\beta_j \in (T \cup N)^*$, $i = 1, 2, \ldots, n$; $j = 1, 2, \ldots, m$,

то непосредственно применять РС-метод нельзя.

Левую рекурсию всегда можно заменить правой:

$A \to \beta_1 A' \mid \ldots \mid \beta_m A'$ // $\boldsymbol{A \to \beta A'}$

$A' \to \alpha_1 A' \mid \ldots \mid \alpha_n A' \mid \varepsilon$ // $\boldsymbol{A' \to \alpha A' \mid \varepsilon}$

Будет получена грамматика, эквивалентная данной, т.к. из нетерминала А по-прежнему выводятся цепочки вида

$\beta_j \{\alpha_i\}$, где $i = 1,2,\ldots,n$; $j = 1,2,\ldots,m$.

Преобразования грамматик

2) Если в грамматике есть нетерминал, у которого **несколько** правил вывода, и среди них есть правила, **начинающиеся нетерминальными символами**, т.е. имеют вид:

$A \to B_1\alpha_1 \mid \ldots \mid B_n\alpha_n \mid a_1\beta_1 \mid \ldots \mid a_m\beta_m$ // $\boldsymbol{A \to B\alpha \mid C\beta}$

$B_1 \to \gamma_{11} \mid \ldots \mid \gamma_{1k}$ // $\boldsymbol{B \to \gamma 1 \mid \gamma 2}$

. . . // $\boldsymbol{C \to \delta 1 \mid \delta 2}$

$B_n \to \gamma_{n1} \mid \ldots \mid \gamma_{np}$,

где $B_i \in N$; $a_j \in T$; α_i, β_j, $\gamma_{ij} \in (T \cup N)^*$,

то можно заменить вхождения нетерминалов B_i их правилами вывода в надежде, что правила вывода из нетерминала A станут удовлетворять требованиям метода рекурсивного спуска:

$A \to \gamma_{11}\alpha_1 \mid \ldots \mid \gamma_{1k}\alpha_1 \mid \ldots \mid \gamma_{n1}\alpha_n \mid \ldots \mid \gamma_{np}\alpha_n \mid a_1\beta_1 \mid \ldots \mid a_m\beta_m$

// $\boldsymbol{A \to \gamma 1\alpha \mid \gamma 12\alpha \mid \delta 1\beta \mid \delta 2\beta}$

Преобразования грамматик

3) Если в грамматике есть нетерминал, у которого несколько правил вывода начинаются **одинаковыми терминальными символами**, т.е. имеют вид

$A \to a\alpha_1 \mid a\alpha_2 \mid \dots \mid a\alpha_n \mid \beta_1 \mid \dots \mid \beta_m$, // $\boldsymbol{A \to a}\alpha_1 \mid \boldsymbol{a}\alpha_2 \mid \beta$

где $a \in T$; α_i, $\beta_j \in (T \cup N)^*$,

то непосредственно применять РС-метод нельзя. Можно преобразовать правила вывода данного нетерминала, объединив правила с общими началами в одно правило:

$A \to aA' \mid \beta_1 \mid \dots \mid \beta_m$ // $\boldsymbol{A \to aA'} \mid \beta$

$A' \to \alpha_1 \mid \alpha_2 \mid \dots \mid \alpha_n$ // $\boldsymbol{A'} \to \alpha_1 \mid \alpha_2$

Будет получена грамматика, эквивалентная данной.

Преобразования грамматик

4) Если в правилах вывода грамматики есть пустая альтернатива, т.е. есть правила вида

$$A \to a_1\alpha_1 \mid \ldots \mid a_n\alpha_n \mid \varepsilon \, ,$$

то метод рекурсивного спуска может оказаться неприменимым.

Например, для грамматики G = ({ a, b }, { S, A }, P, S), где

P: $S \to bAa$ // $S \to bAc$

$A \to aA \mid \varepsilon$

РС-анализатор, реализованный по обычной схеме, будет таким:

```
void S ( ) {
    if (c == 'b') {
        gc( ); A( );
        if (c != 'a')  throw c; }
    else throw c;
}
```

```
void A( ) {
    if (c == 'a') {
        gc();  A(); }
}
```

Тогда при анализе цепочки **baa** функция A( ) будет вызвана два раза; она прочитает подцепочку aa, хотя второй символ a - это часть подцепочки, выводимой из S. В результате окажется, что baa не принадлежит языку, порождаемому грамматикой, но в действительности это не так.

Т.е. если **FIRST(A) ∩ FOLLOW(A) ≠ ∅ ,** то метод рекурсивного спуска **неприменим** к данной грамматике.

Итак, если в грамматике есть правила с пустой альтернативой вида:

$A \to \alpha_1 A \mid \ldots \mid \alpha_n A \mid \beta_1 \mid \ldots \mid \beta_m \mid \varepsilon$

$B \to \alpha A \beta$

и *first*(A) $\cap$ *follow*(A) $\neq \varnothing$ (из-за вхождения A в правила вывода для B), то можно преобразовать грамматику, заменив правило вывода из В на следующие два правила:

$B \to \alpha A'$

$A' \to \alpha_1 A' \mid \ldots \mid \alpha_n A' \mid \beta_1 \beta \mid \ldots \mid \beta_m \beta \mid \beta$

Полученная грамматика будет эквивалентна исходной, т. к. из B по-прежнему выводятся цепочки вида $\alpha \{\alpha_i\} \beta_j \beta$ либо $\alpha \{\alpha_i\} \beta$.

Однако правило вывода для нетерминального символа A' будет иметь альтернативы, начинающиеся одинаковыми терминальными символами (т. к. *first*(A) $\cap$ *follow*(A) $\neq \varnothing$); следовательно, потребуются дальнейшие преобразования, и успех не гарантирован.

Пример преобразования грамматики

$S \rightarrow fASd \mid \varepsilon$ $A \rightarrow \underline{Aa} \mid \underline{Ab} \mid dB \mid f$ $B \rightarrow bcB \mid \varepsilon$	$\Rightarrow$	$S \rightarrow fASd \mid \varepsilon$ $A \rightarrow \underline{dBA'} \mid fA'$ $A' \rightarrow aA' \mid bA' \mid \varepsilon$ $B \rightarrow bcB \mid \varepsilon$

FIRST(S) = { f }, FOLLOW(S) = { d }; $\cap = \varnothing$

FIRST(A') = { a, b }, FOLLOW(A') = { f, d }; $\cap = \varnothing$

FIRST(B) = { b }, FOLLOW(B) = { a, b, f, d }; $\cap = \{b\} \neq \varnothing$

$S \rightarrow fASd \mid \varepsilon$

$A \rightarrow dB' \mid fA'$

$\Rightarrow$ $B' \rightarrow bcB' \mid A'$ $\rightarrow$ $B' \rightarrow \underline{bcB'} \mid aA' \mid \underline{bA'} \mid \varepsilon$

$A' \rightarrow aA' \mid bA' \mid \varepsilon$

$B \rightarrow bcB \mid \varepsilon$ - недостижимые правила, их можно убрать.

$S \rightarrow fASd \mid \varepsilon$

$A \rightarrow dB' \mid fA'$

$\Rightarrow$ $B' \rightarrow \underline{bC} \mid aA' \mid \varepsilon$

$C \rightarrow \underline{cB'} \mid A'$ $\rightarrow$ $C \rightarrow \underline{cB'} \mid aA' \mid \underline{bA'} \mid \varepsilon$

$A' \rightarrow aA' \mid bA' \mid \varepsilon$

S - не менялось,

FIRST(B') = { a, b }, FOLLOW(B') = { f, d }; $\cap = \varnothing$

FIRST(A') = { a, b }, FOLLOW(A') = { f, d }; $\cap = \varnothing$

FIRST(C) = { a, b, c}, FOLLOW(C) = { f, d }; $\cap = \varnothing$

Т.е. получили эквивалентную грамматику, к которой применим метод рекурсивного спуска.

Синтаксический анализатор для М-языка

```
class Parser {
        Lex curr_lex;
        type_of_lex c_type;
        int c_val;
        Scanner scan;
        Stack < int, 100 > st_int;
        Stack < type_of_lex, 100 >  st_lex;
        void P();   void D1();   void D ();   void B ();   void S ();
        void E();   void E1();   void T();   void F();
        void dec ( type_of_lex type);    void check_id ();
        void check_op ();    void check_not ();    void eq_type ();
        void eq_bool ();    void check_id_in_read ();
        void gl ( ) {
                curr_lex = scan.get_lex ();
                c_type = curr_lex.get_type ();
                c_val = curr_lex.get_value ();
        }
    public:
        Poliz  prog;
        Parser (const char *program) : scan (program), prog (1000) { }
        void analyze ( );
};
```

Синтаксический анализатор для М-языка

```
void Parser::analyze () {
                gl ();
                P ();
                prog.print ();
                cout << endl << "Yes!!!" << endl;
}

void Parser::P () {
        if (c_type == LEX_PROGRAM)
                gl ();
        else
                throw curr_lex;
        D1();
        if (c_type == LEX_SEMICOLON)
                gl ();
        else
                throw curr_lex;
        B ();
        if (c_type != LEX_FIN)
                throw curr_lex;
}
```

Другие методы распознавания КС-языков.

Существуют другие методы анализа, анализаторы по которым применимы к более широким подклассам КС-грамматик, чем РС-анализатор, но обладающие теми же свойствами: входная цепочка считывается **один раз слева направо**, процесс разбора **детерминирован**, и в результате на обработку цепочки длины **n** расходуется время **cn**.

Например:

Анализатор для LL(k)-грамматик осуществляет левосторонний вывод (анализ сверху-вниз) , принимая во внимание **k** входных символов, расположенных справа, от текущей позиции .

Анализатор для LR(k)-грамматик осуществляет правосторонний вывод (анализ снизу-вверх), принимая во внимание **k** входных символов, расположенных справа, от текущей позиции.

Анализатор для грамматик предшествования осуществляет правосторонний вывод (анализ снизу-вверх) , учитывая только некоторые отношения между парами смежных символов выводимой цепочки.

Другие методы распознавания КС-языков.

Любая грамматика, анализируемая **РС**-методом, является **LL(1**)-грамматикой - обратное неверно.

Любая **LL**-грамматика является **LR**-грамматикой - обратное неверно.

Левосторонний (нисходящий) синтаксический анализ предпочтителен с точки зрения процесса трансляции, поскольку на его основе легче организовать процесс порождения цепочек результирующего языка.

Восходящий синтаксический анализ привлекательнее тем, что часто для языков программирования легче построить правоанализируемую грамматику, а на ее основе - правосторонний распознаватель.

Конкретный выбор анализатора зависит от конкретного компилятора, от сложности грамматики входного языка программирования и от того, как будут использованы результаты работы анализатора.