

# Коды

Т. А. Новикова

Факультет ВМиК  
Казахстанский филиал МГУ им.М. В. Ломоносова

5 мая 2016 г.

Пусть  $A = \{a_1, a_2, \dots, a_r\}$  — исходный алфавит,  
 $B = \{b_1, \dots, b_m\}$  — кодирующий алфавит и

$$A^* = \emptyset \cup A \cup A^2 \cup \dots \cup A^n \cup \dots,$$

$$B^* = \emptyset \cup B \cup B^2 \cup \dots \cup B^n \cup \dots$$

Под  $A^n$  будем понимать все слова длины  $n$  в алфавите  $A$ .

Пусть  $A = \{a_1, a_2, \dots, a_r\}$  — исходный алфавит,  
 $B = \{b_1, \dots, b_m\}$  — кодирующий алфавит и

$$A^* = \emptyset \cup A \cup A^2 \cup \dots \cup A^n \cup \dots,$$

$$B^* = \emptyset \cup B \cup B^2 \cup \dots \cup B^n \cup \dots$$

Под  $A^n$  будем понимать все слова длины  $n$  в алфавите  $A$ .

### Definition

Алфавитным кодированием  $A^* \rightarrow B^*$  назовем отображение  $\phi : A \rightarrow B^*$  такое, что  $a_i \rightarrow B_i$ .

Пусть  $A = \{a_1, a_2, \dots, a_r\}$  — исходный алфавит,  
 $B = \{b_1, \dots, b_m\}$  — кодирующий алфавит и

$$A^* = \emptyset \cup A \cup A^2 \cup \dots \cup A^n \cup \dots,$$

$$B^* = \emptyset \cup B \cup B^2 \cup \dots \cup B^n \cup \dots$$

Под  $A^n$  будем понимать все слова длины  $n$  в алфавите  $A$ .

### Definition

Алфавитным кодированием  $A^* \rightarrow B^*$  назовем отображение  $\phi : A \rightarrow B^*$  такое, что  $a_i \rightarrow B_i$ .

Множество  $\{B_1, \dots, B_r\}$  называется множеством кодовых слов и считается, что  $\phi : a_{i_1} a_{i_2} \dots a_{i_k} \rightarrow B_{i_1} B_{i_2} \dots B_{i_k}$ .

Договоримся обозначать  $\bar{a}$  последовательную конкатенацию символов.

Кодирование  $A^* \rightarrow B^*$  называется **взаимно однозначным (декодируемым, делимым)**, если для любых слов  $\bar{a}_1 \in A^*, \bar{a}_2 \in A^*$  верно, что  $\bar{a}_1 \neq \bar{a}_2 \Rightarrow \phi(\bar{a}_1) \neq \phi(\bar{a}_2)$ .

Договоримся обозначать  $\bar{a}$  последовательную конкатенацию символов.

Кодирование  $A^* \rightarrow B^*$  называется **взаимно однозначным (декодируемым, делимым)**, если для любых слов  $\bar{a}_1 \in A^*, \bar{a}_2 \in A^*$  верно, что  $\bar{a}_1 \neq \bar{a}_2 \Rightarrow \phi(\bar{a}_1) \neq \phi(\bar{a}_2)$ .

Код называется **равномерным**, если длины всех его кодовых слов одинаковы.

Договоримся обозначать  $\bar{a}$  последовательную конкатенацию символов.

Кодирование  $A^* \rightarrow B^*$  называется **взаимно однозначным (декодируемым, делимым)**, если для любых слов  $\bar{a}_1 \in A^*, \bar{a}_2 \in A^*$  верно, что  $\bar{a}_1 \neq \bar{a}_2 \Rightarrow \phi(\bar{a}_1) \neq \phi(\bar{a}_2)$ .

Код называется **равномерным**, если длины всех его кодовых слов одинаковы.

**Утв.1:** любой равномерный код является взаимно однозначным.

Код называется **префиксным**, если никакое кодовое слово не является началом другого.



Код называется **префиксным**, если никакое кодовое слово не является началом другого.

**Утв.2:** любое префиксное кодирование является взаимно однозначным.

Код называется **префиксным**, если никакое кодовое слово не является началом другого.

**Утв.2:** любое префиксное кодирование является взаимно однозначным.

Код называется **постфиксным (суффиксным)**, если никакое кодовое слово не является концом другого.

Код называется **префиксным**, если никакое кодовое слово не является началом другого.

**Утв.2:** любое префиксное кодирование является взаимно однозначным.

Код называется **постфиксным (суффиксным)**, если никакое кодовое слово не является концом другого. **Утв.3:** любое постфиксное кодирование является взаимно однозначным.

## Definition

Слово  $\bar{b} \in B^*$  называется неприводимым, если  $\bar{b}$  декодируется неоднозначно, однако, при выбрасывании из  $\bar{b}$  любого связного непустого куска получается слово, которое декодируется не более, чем одним способом.

## Theorem (Марков А.А.)

Пусть  $\phi : a_i \rightarrow B_i$  — некоторое кодирование. Пусть  $W$  — максимальное число кодовых слов, которые помещаются подряд внутри кодового слова. Пусть  $l_i$  — длина слова  $B_i$ ,  $L = \sum_{i=1}^r l_i$ . Тогда если кодирование  $\phi$  не взаимно однозначно, то существуют два различных слова  $a' \in A^*$ ,  $a'' \in A^*$ ,

$$\text{len}(a') \leq \left\lfloor \frac{(W+1)(L-r+2)}{2} \right\rfloor,$$

$$\text{len}(a'') \leq \left\lfloor \frac{(W+1)(L-r+2)}{2} \right\rfloor$$

и при этом  $\phi(a') = \phi(a'')$ .

**Доказательство.** Пусть  $\phi$  не является взаимно однозначным. Тогда существует некоторое слово  $\overline{b_1}$ , которое допускает две расшифровки. Если слово  $\overline{b_1}$  не является неприводимым, то выбрасывая из  $\overline{b_1}$  куски несколько раз, получим неприводимое слово  $\overline{b}$  иначе, положим  $\overline{b} = \overline{b_1}$ . Это всегда можно сделать.

**Доказательство.** Пусть  $\phi$  не является взаимно однозначным. Тогда существует некоторое слово  $\bar{b}_1$ , которое допускает две расшифровки. Если слово  $\bar{b}_1$  не является неприводимым, то выбрасывая из  $\bar{b}_1$  куски несколько раз, получим неприводимое слово  $\bar{b}$  иначе, положим  $\bar{b} = \bar{b}_1$ . Это всегда можно сделать.

Рассмотрим любые две декодировки слова  $\bar{b}$ . Разрежем слово  $\bar{b}$  в конечных точках кодовых слов каждого из разбиений. Слова нового разбиения разделим на два класса: к I классу отнесём слова, являющиеся элементарными кодами, а ко II классу — все слова, являющиеся началами кодовых слов одного разбиения и концами слов второго разбиения.

## Lemma

Если  $\bar{b}$  — неприводимое слово, то все слова  $\beta_1, \beta_2, \dots, \beta_m$  II класса различны.



## Lemma

Если  $\bar{b}$  — неприводимое слово, то все слова  $\beta_1, \beta_2, \dots, \beta_m$  II класса различны.

**Доказательство.** Пусть  $\beta' = \beta''$ . Тогда очевидно, что слово  $\bar{b}$  не будет неприводимым, поскольку тогда при выкидывании отрезка между  $\beta', \beta''$  вместе с любым из этих слов, получим снова две различные расшифровки этого слова.

Продолжим доказательство теоремы Маркова.  
Получается, что все  $\beta_1, \dots, \beta_m$  разные. Тогда число слов второго класса не превосходит числа непустых начал элементарных кодов, то есть не превосходит

$$(l_1 - 1) + (l_2 - 1) + \dots + (l_r - 1) = L - r.$$

Продолжим доказательство теоремы Маркова.

Получается, что все  $\beta_1, \dots, \beta_m$  разные. Тогда число слов второго класса не превосходит числа непустых начал элементарных кодов, то есть не превосходит

$$(l_1 - 1) + (l_2 - 1) + \dots + (l_r - 1) = L - r.$$

Слова из второго класса разбивают слово не более чем на  $L - r + 1$  кусков. Рассмотрим пары соседних кусков. Тогда согласно одному разбиению в одной половинке уложится не более одного кодового слова, а в другой — не более  $W$  (согласно второму разбиению ситуация симметрична).

Всего пар кусков не больше, чем

$$\left\lceil \frac{L-r+1}{2} \right\rceil \leq \frac{L-r+2}{2},$$

а в каждом из них укладывается слов не более чем  $W+1$ .

Отсюда число кодовых слов в любом разбиении не превосходит  $\frac{L-r+2}{2}(W+1)$ , а т.к. число целое, то не превосходит целой части  $\left\lfloor \frac{(W+1)(L-r+2)}{2} \right\rfloor$ .

□

## Theorem (Неравенство Макмиллана.)

Пусть задано кодирование  $\varphi : a_i \rightarrow B_i, i = 1, \dots, r$  и пусть в кодирующем алфавите  $B - q$  букв и  $len(B_i) = l_i$ . Тогда если  $\varphi$  взаимно однозначно, то

$$\sum_{i=1}^r \frac{1}{q^{l_i}} \leq 1.$$

## Theorem (Неравенство Макмиллана.)

Пусть задано кодирование  $\varphi : a_i \rightarrow B_i, i = 1, \dots, r$  и пусть в кодирующем алфавите  $B - q$  букв и  $len(B_i) = l_i$ . Тогда если  $\varphi$  взаимно однозначно, то

$$\sum_{i=1}^r \frac{1}{q^{l_i}} \leq 1.$$

**Доказательство.** Положим  $x = \sum_{i=1}^r \frac{1}{q^{l_i}}$ . Тогда для любого натурального  $n$ :

$$x^n = \left(\sum_{i_1=1}^r \frac{1}{q^{l_{i_1}}}\right) \left(\sum_{i_2=1}^r \frac{1}{q^{l_{i_2}}}\right) \dots \left(\sum_{i_n=1}^r \frac{1}{q^{l_{i_n}}}\right) = \sum_{i_1=1}^r \sum_{i_2=1}^r \dots \sum_{i_n=1}^r \frac{1}{q^{l_{i_1} + l_{i_2} + \dots + l_{i_n}}}.$$

Обозначая  $l_{max} = \max_{1 \leq i \leq r} l_i$ , получим, что эта сумма равна  $\sum_{k=1}^{n \cdot l_{max}} \frac{c_k}{q^k}$  для некоторых  $c_k$ .

## Лемма

Для любого  $k$  верно  $c_k \leq q^k$ .

**Доказательство.** За  $c_k$  в предыдущей формуле фактически обозначено число наборов  $(i_1, \dots, i_n)$ , для которых  $i_1 + i_2 + \dots + i_n = k$ . Но такой сумме соответствует слово  $B_{i_1} B_{i_2} \dots B_{i_n}$  и  $\text{len}(B_{i_1} B_{i_2} \dots B_{i_n}) = i_1 + i_2 + \dots + i_n = k$ .

## Лемма

Для любого  $k$  верно  $c_k \leq q^k$ .

**Доказательство.** За  $c_k$  в предыдущей формуле фактически обозначено число наборов  $(i_1, \dots, i_n)$ , для которых  $i_1 + i_2 + \dots + i_n = k$ . Но такой сумме соответствует слово  $B_{i_1} B_{i_2} \dots B_{i_n}$  и  $\text{len}(B_{i_1} B_{i_2} \dots B_{i_n}) = i_1 + i_2 + \dots + i_n = k$ . В силу однозначности кодирования различным наборам соответствуют различные сообщения, а различных сообщений длины  $k$  в алфавите из  $q$  букв не более  $q^k$ , значит,  $c_k \leq q^k$ .



Согласно лемме,  $x^n = \sum_{k=1}^{n \cdot l_{\max}} \frac{c_k}{q^k} \leq \sum_{k=1}^{n \cdot l_{\max}} 1 = n l_{\max}$ , но это равнозначно тому, что  $x \leq \sqrt[n]{n l_{\max}}, \forall n$ . Устремим  $n$  к бесконечности, получим, что  $x \leq 1$ . □

## Theorem

Если  $|B| = q$  и натуральные числа  $l_1, l_2, \dots, l_r$  удовлетворяют неравенству

$$\sum_{i=1}^r \frac{1}{q^{l_i}} \leq 1,$$

то существует префиксный код  $B_1, B_2, \dots, B_r$  такой, что  $\text{len}(B_i) = l_i$ .

## Theorem

Если  $|B| = q$  и натуральные числа  $l_1, l_2, \dots, l_r$  удовлетворяют неравенству

$$\sum_{i=1}^r \frac{1}{q^{l_i}} \leq 1,$$

то существует префиксный код  $B_1, B_2, \dots, B_r$  такой, что  $\text{len}(B_i) = l_i$ .

**Доказательство.** Пусть  $\sum_{i=1}^r \frac{1}{q^{l_i}} \leq 1$  и для любого  $k$  существует ровно  $d_k$  таких  $i$ , что  $l_i = k$ , то есть  $\sum_{k=1}^{l_{\max}} \frac{d_k}{q^k} \leq 1$ .

## Theorem

Если  $|B| = q$  и натуральные числа  $l_1, l_2, \dots, l_r$  удовлетворяют неравенству

$$\sum_{i=1}^r \frac{1}{q^{l_i}} \leq 1,$$

то существует префиксный код  $B_1, B_2, \dots, B_r$  такой, что  $\text{len}(B_i) = l_i$ .

**Доказательство.** Пусть  $\sum_{i=1}^r \frac{1}{q^{l_i}} \leq 1$  и для любого  $k$  существует ровно  $d_k$  таких  $i$ , что  $l_i = k$ , то есть  $\sum_{k=1}^{l_{\max}} \frac{d_k}{q^k} \leq 1$ .

Тогда надо построить префиксный код, в котором ровно  $d_1$  слов длины 1,  $d_2$  слов длины 2 и т.д. Имеем, что для любого  $m$ :  $\sum_{k=1}^m \frac{d_k}{q^k} \leq 1$ , а это означает:

$$\begin{aligned} \frac{d_1}{q} + \frac{d_2}{q^2} + \dots + \frac{d_{m-1}}{q^{m-1}} + \frac{d_m}{q^m} &\leq 1 \\ \Leftrightarrow d_m &\leq q^m - (d_1 q^{m-1} + d_2 q^{m-2} + \dots + d_{m-1} q). \end{aligned}$$

Рассмотрим это неравенство для  $m = 1 : d_1 \leq q$ . Для слов длины 1 всего предоставляется ровно  $q$  вариантов в алфавите мощности  $q$ .

Рассмотрим это неравенство для  $m = 1 : d_1 \leq q$ . Для слов длины 1 всего предоставляется ровно  $q$  вариантов в алфавите мощности  $q$ .

После выбора  $d_1$  слов длины 1 рассмотрим неравенство для  $m = 2 : d_2 \leq q^2 - d_1 q$ . Всего слов длины 2 существует  $q^2$ , но все они могут начинаться лишь с тех букв, которые не были выбраны в качестве слов длины 1, значит, остается ровно  $q^2 - d_1 q$  возможностей выбрать слова длины 2, что удовлетворяет  $d_2 \leq q^2 - d_1 q$ .

Рассмотрим это неравенство для  $m = 1 : d_1 \leq q$ . Для слов длины 1 всего предоставляется ровно  $q$  вариантов в алфавите мощности  $q$ .

После выбора  $d_1$  слов длины 1 рассмотрим неравенство для  $m = 2 : d_2 \leq q^2 - d_1 q$ . Всего слов длины 2 существует  $q^2$ , но все они могут начинаться лишь с тех букв, которые не были выбраны в качестве слов длины 1, значит, остается ровно  $q^2 - d_1 q$  возможностей выбрать слова длины 2, что удовлетворяет  $d_2 \leq q^2 - d_1 q$ .

Если мы таким образом выберем необходимое количество слов длины 1, 2 и т.д., до слов длин  $m - 1$ . Тогда для слов длины  $m$  разрешено возможностей не меньше, чем  $q^m - d_{m-1}q - d_{m-2}q^2 - \dots - d_2q^{m-2} - d_1q^{m-1}$ , что удовлетворяет условию. □

Будем рассматривать кодирование в алфавит  $\{0, 1\}$ . Пусть известны некоторые частоты  $a_1 : p_1, a_2 : p_2, \dots, a_k : p_k$  появления символов кодируемого алфавита в тексте.



Будем рассматривать кодирование в алфавит  $\{0, 1\}$ . Пусть известны некоторые частоты  $a_1 : p_1, a_2 : p_2, \dots, a_k : p_k$  появления символов кодируемого алфавита в тексте.

## Definition

Ценой (стоимостью, избыточностью) кодирования  $\varphi$  называется функция  $c(\varphi) = \sum_{i=1}^k p_i l_i$ . При кодировании текста длины  $N$  его длина становится примерно равной

$$\sum_{i=1}^k (Np_i) l_i = N \sum_{i=1}^k p_i l_i.$$

## Definition

Взаимно однозначное кодирование  $\varphi$  называется оптимальным, если на нем достигается  $\inf_{\varphi} c(\varphi)$ , где грань достигается по всем взаимно однозначным кодированиям  $\varphi$ .

## Definition

Взаимно однозначное кодирование  $\varphi$  называется оптимальным, если на нем достигается  $\inf_{\varphi} c(\varphi)$ , где грань достигается по всем взаимно однозначным кодированиям  $\varphi$ .

**Справедливо утверждение:** если существует оптимальный код, то существует оптимальный префиксный код с тем же спектром длин слов.

## Lemma

Если  $\varphi$  — оптимальное кодирование и  $p_i > p_j$ , то  $l_i \leq l_j$ .

**Доказательство.** Допустим, что  $p_i > p_j$  и  $l_i > l_j$ . Рассмотрим кодирование  $\varphi$  и рассмотрим кодирование  $\varphi'$ , в котором переставим кодовые слова  $B_i, B_j$ : если раньше  $a_i \rightarrow B_i, a_j \rightarrow B_j$ , то теперь  $a_i \rightarrow B_j, a_j \rightarrow B_i$ .

## Lemma

Если  $\varphi$  — оптимальное кодирование и  $p_i > p_j$ , то  $l_i \leq l_j$ .

**Доказательство.** Допустим, что  $p_i > p_j$  и  $l_i > l_j$ . Рассмотрим кодирование  $\varphi$  и рассмотрим кодирование  $\varphi'$ , в котором переставим кодовые слова  $B_i, B_j$ : если раньше  $a_i \rightarrow B_i, a_j \rightarrow B_j$ , то теперь  $a_i \rightarrow B_j, a_j \rightarrow B_i$ .

Тогда

$$c(\varphi) - c(\varphi') = (p_i l_i + p_j l_j) - (p_i l_j + p_j l_i) = (p_i - p_j)(l_i - l_j) > 0,$$
значит,  $c(\varphi') < c(\varphi)$ , то есть  $\varphi$  не является оптимальным  $\Rightarrow$   
**?!.**

## Lemma

Если  $\varphi$  — оптимальное префиксное кодирование и  $l_{\max} = \max l_i$ ,  $\text{len}(B_j) = l_{\max}$ ,  $B_j = B'_j \alpha$ , где  $\alpha \in \{0, 1\}$ , то в коде существует слово  $B_r$  такое, что  $B_r = B'_j \bar{\alpha}$ .

## Lemma

Если  $\varphi$  — оптимальное префиксное кодирование и  $l_{\max} = \max_i l_i$ ,  $len(B_j) = l_{\max}$ ,  $B_j = B'_j\alpha$ , где  $\alpha \in \{0, 1\}$ , то в коде существует слово  $B_r$  такое, что  $B_r = B'_j\bar{\alpha}$ .

**Доказательство.** Допустим, что в  $\varphi$  нет слова  $B'_j\bar{\alpha}$ . Тогда заменим в  $\varphi$   $B'_j\alpha$  на  $B'_j$ . Получим код  $\varphi'$ , который является префиксным, но

$$c(\varphi) - c(\varphi') = p_j len(B'_j\alpha) - p_j len(B'_j) = p_j,$$

но тогда снова код  $\varphi$  не является оптимальным — **?!.**

## Lemma

Если  $\varphi$  — оптимальное префиксное кодирование и  $p_1 \geq p_2 \geq \dots \geq p_{k-1} \geq p_k$ , то можно так переставить в коде  $\varphi$ , что получится оптимальное префиксное кодирование  $\varphi'$  такое, что слова  $B'_{k-1}, B'_k$  в нем будут отличаться только в последнем разряде.



## Lemma

Если  $\varphi$  — оптимальное префиксное кодирование и  $p_1 \geq p_2 \geq \dots \geq p_{k-1} \geq p_k$ , то можно так переставить в коде  $\varphi$ , что получится оптимальное префиксное кодирование  $\varphi'$  такое, что слова  $B'_{k-1}, B'_k$  в нем будут отличаться только в последнем разряде.

**Доказательство.** Пусть  $p_1 \geq p_2 \geq \dots \geq p_{k-1} \geq p_k$ . По предыдущей лемме в коде  $\varphi$  есть слова  $B'0, B'1$  максимальной длины. Поменяем их местами с  $B_{k-1}, B_k$ . Так как  $p_{k-1} \leq p_i, p_k \leq p_i$  для  $1 \leq i \leq k_2$ , то цена кодирования не увеличится и код останется оптимальным.

## Lemma

Рассмотрим кодирования  $\varphi : B_1(p_1), B_2(p_2), \dots, B_k(p_k)$  и  $\varphi' : B_1(p_1), \dots, B_{k-1}(p_{k-1}), B_k 0(p'), B_k 1(p'')$ , где  $p' + p'' = p_k$ . Если один из этих наборов префиксный, то второй также префиксный и  $c(\varphi') = c(\varphi) + p_k$ .

## Lemma

Рассмотрим кодирования  $\varphi : B_1(p_1), B_2(p_2), \dots, B_k(p_k)$  и  $\varphi' : B_1(p_1), \dots, B_{k-1}(p_{k-1}), B_k 0(p'), B_k 1(p'')$ , где  $p' + p'' = p_k$ . Если один из этих наборов префиксный, то второй также префиксный и  $c(\varphi') = c(\varphi) + p_k$ .

**Доказательство.** Рассмотрим

$$\begin{aligned} c(\varphi') - c(\varphi) &= p' \text{len}(B_k 0) + p'' \text{len}(B_k 1) - p_k \text{len}(B_k) = \\ &= p'(l_k + 1) + p''(l_k + 1) - p_k l_k = \\ &= (p' + p'')l_k + (p' + p'') - p_k l_k = p_k. \end{aligned}$$

## Theorem (Теорема редукции.)

Пусть заданы два набора частот и два набора слов:

$\varphi : B_1(p_1), B_2(p_2), \dots, B_k(p_k)$  и

$\varphi' : B_1(p_1), \dots, B_{k-1}(p_{k-1}), B_k 0(p'), B_k 1(p'')$ .

- 1 Тогда если  $\varphi'$  — оптимальное префиксное кодирование, то и  $\varphi$  — оптимальное префиксное кодирование.
- 2 Если же  $\varphi$  — оптимальное префиксное кодирование и  $p_1 \geq p_2 \geq \dots \geq p_{k-1} \geq p' \geq p''$ , то  $\varphi'$  — также оптимальное префиксное кодирование.

**Доказательство.** 1). Префиксность исходного кода очевидна. Покажем его оптимальность. Пусть это не так,  $\varphi$  — не оптимально. Тогда существует префиксный код  $\varphi_1 : \mathbf{c}(\varphi_1) < \mathbf{c}(\varphi)$  для тех же распределений частот.

**Доказательство.** 1). Префиксность исходного кода очевидна. Покажем его оптимальность. Пусть это не так,  $\varphi$  — не оптимально. Тогда существует префиксный код  $\varphi_1 : c(\varphi_1) < c(\varphi)$  для тех же распределений частот.

Пусть  $\varphi_1 : D_1(p_1), D_2(p_2), \dots, D_k(p_k)$ . Рассмотрим новое кодирование:  $\varphi'_1 : D_1(p_1), D_2(p_2), \dots, D_k 0(p'), D_k 1(p'')$ . Вновь полученное кодирование также является префиксным и из того, что  $c(\varphi') = c(\varphi) + p_k$ ,  $c(\varphi'_1) = c(\varphi_1) + p_k$  следует, что  $c(\varphi_1) < c(\varphi)$ , а это означает, что  $c(\varphi'_1) = c(\varphi_1) + p_k < c(\varphi) + p_k = c(\varphi')$ .

Но тогда  $\varphi'$  не является оптимальным кодированием, что противоречит условию  $\Rightarrow \varphi$  оптимально.

2). Пусть  $\varphi$  — оптимальное префиксное кодирование и  $p_1 \geq p_2 \geq \dots \geq p_{k-1} \geq p' \geq p''$ . Допустим, что  $\varphi'$  не оптимально. Тогда для частот  $p_1, p_2, \dots, p_{k-1}, p', p''$  существует оптимальное префиксное кодирование  $\varphi'_1 : D_1, \dots, D_{k-1}, D_k 0, D_k 1$  и  $c(\varphi'_1) < c(\varphi)$ . Тогда для частот  $p_1, p_2, \dots, p_k$  рассмотрим кодирование  $\varphi_1 : D_1, \dots, D_{k-1}, D_k$ . Получим

$$c(\varphi_1) = c(\varphi'_1) - p_k < c(\varphi') - p_k = c(\varphi) \Rightarrow c(\varphi_1) < c(\varphi)$$

и  $\varphi$  не оптимально, что противоречит условию. □

В этом разделе будем рассматривать равномерные коды с длиной кодового слова  $n$ , а также ошибки замещения, когда бит  $\alpha$  заменяется на бит  $\bar{\alpha}$ .



В этом разделе будем рассматривать равномерные коды с длиной кодового слова  $n$ , а также ошибки замещения, когда бит  $\alpha$  заменяется на бит  $\bar{\alpha}$ .

### Definition

Код называется **исправляющим  $r$  ошибок**, если при наличии в любом кодовом слове не более  $r$  ошибок типа замещения можно восстановить исходное кодовое слово.

### Definition

**Расстоянием Хэмминга**  $\rho(\tilde{\alpha}_1, \tilde{\alpha}_2)$  между 2 наборами длины  $n$  называется число разрядов, в которых эти наборы различаются.

### Definition

**Шаром (сферой) радиуса  $r$  с центром в точке  $\tilde{\alpha} = (\alpha_1, \dots, \alpha_n)$**  называется множество всех наборов длины  $n$ , расстояние от которых до  $\tilde{\alpha}$  не превосходит  $r$  (в точности равно  $r$ ).

## Definition

Кодовым расстоянием называется расстояние Хэмминга:

$$\rho_{min} = \min_{\alpha_i, \alpha_j} \rho(\tilde{\alpha}_i, \tilde{\alpha}_j).$$

**Утверждение.** Код  $K = \{\tilde{\alpha}_1, \tilde{\alpha}_2, \dots, \tilde{\alpha}_m\}$  исправляет  $r$  ошибок тогда и только тогда, когда  $\rho_{min}(K) \geq 2r + 1$ .

## Definition

Кодовым расстоянием называется расстояние Хэмминга:

$$\rho_{\min} = \min_{\alpha_i, \alpha_j} \rho(\tilde{\alpha}_i, \tilde{\alpha}_j).$$

**Утверждение.** Код  $K = \{\tilde{\alpha}_1, \tilde{\alpha}_2, \dots, \tilde{\alpha}_m\}$  исправляет  $r$  ошибок тогда и только тогда, когда  $\rho_{\min}(K) \geq 2r + 1$ .

**Идея доказательства.** Рассмотрим шары, соответствующие наборам, их радиус должен совпадать с  $r$ . Чтобы эти шары не пересекались, расстояние должно быть не меньше, чем  $2r + 1$ .

## Definition

Код обнаруживает  $r$  ошибок, если при наличии в нём не более  $r$  ошибок типа замещения можно сказать, были ошибки, или их не было.

**Утверждение.** Код  $K = \{\tilde{\alpha}_1, \tilde{\alpha}_2, \dots, \tilde{\alpha}_m\}$  обнаруживает  $r$  ошибок тогда и только тогда, когда  $\rho_{\min}(K) \geq r + 1$ .

## Definition

Код обнаруживает  $r$  ошибок, если при наличии в нём не более  $r$  ошибок типа замещения можно сказать, были ошибки, или их не было.

**Утверждение.** Код  $K = \{\tilde{\alpha}_1, \tilde{\alpha}_2, \dots, \tilde{\alpha}_m\}$  обнаруживает  $r$  ошибок тогда и только тогда, когда  $\rho_{\min}(K) \geq r + 1$ .

**Идея доказательства.** Условие утверждения эквивалентно тому, что ни один из центров шаров (кодированное слово) не содержится в каком-либо другом шаре.

## Definition

Функция  $M_r(n)$  есть максимальное число слов длины  $n$ , образующих код, исправляющий  $r$  ошибок.  $S_r(n)$  — число точек (наборов длины  $n$ ) в шаре радиуса  $r$ .

Утверждение.  $S_r(n) = 1 + C_n^1 + C_n^2 + \dots + C_n^r$ .

## Definition

Функция  $M_r(n)$  есть максимальное число слов длины  $n$ , образующих код, исправляющий  $r$  ошибок.  $S_r(n)$  — число точек (наборов длины  $n$ ) в шаре радиуса  $r$ .

**Утверждение.**  $S_r(n) = 1 + C_n^1 + C_n^2 + \dots + C_n^r$ .

**Доказательство.** Точки шара радиуса  $r$  — это его центр, множество наборов, отличающихся от центра в одной координате —  $C_n^1$ , множество наборов, отличающихся в двух координатах —  $C_n^2$  и т.д. Получаем исходное утверждение.

## Theorem

$$\frac{2^n}{S_{2r}(n)} \leq M_r(n) \leq \frac{2^n}{S_r(n)}.$$

**Доказательство.** Рассмотрим произвольный код  $K = \{\tilde{\alpha}_1, \tilde{\alpha}_2, \dots, \tilde{\alpha}_m\}$ , исправляющий  $r$  ошибок. Из утверждения 1 следует, что шары радиуса  $r$  не могут пересекаться, следовательно, число всех точек всех шаров не превосходит числа точек  $n$ -мерного куба и

$$m \cdot S_r(n) \leq 2^n \Leftrightarrow m \leq \frac{2^n}{S_r(n)} \Rightarrow M_r(n) \leq \frac{2^n}{S_r(n)}.$$



## Theorem

$$\frac{2^n}{S_{2r}(n)} \leq M_r(n) \leq \frac{2^n}{S_r(n)}.$$

**Доказательство.** Рассмотрим произвольный код  $K = \{\tilde{\alpha}_1, \tilde{\alpha}_2, \dots, \tilde{\alpha}_m\}$ , исправляющий  $r$  ошибок. Из утверждения 1 следует, что шары радиуса  $r$  не могут пересекаться, следовательно, число всех точек всех шаров не превосходит числа точек  $n$ -мерного куба и

$$m \cdot S_r(n) \leq 2^n \Leftrightarrow m \leq \frac{2^n}{S_r(n)} \Rightarrow M_r(n) \leq \frac{2^n}{S_r(n)}.$$

Будем строить сам код  $K$ . Выберем произвольную точку  $\tilde{\alpha}_1$ . В качестве точки  $\tilde{\alpha}_2$  мы не можем взять точки шара радиуса  $2r$  с центром в точке  $\tilde{\alpha}_1$ .

Пусть уже выбраны  $k$  наборов. Для выбора набора  $\tilde{\alpha}_{k+1}$  запрещено точек не больше, чем  $k \cdot S_{2r}(n)$ , то есть, если  $k \cdot S_{2r}(n) < 2^n$ , мы можем выбрать следующий набор. Рано или поздно встретится элемент  $m$  такой, что

$$m \cdot S_{2r}(n) \geq 2^n \Leftrightarrow m \geq \frac{2^n}{S_{2r}(n)} \Rightarrow M_r(n) \geq \frac{2^n}{S_{2r}(n)}.$$

□

Рассмотрим коды, исправляющие одну ошибку типа замещения в словах длины  $n$ . Выберем натуральное  $k$  таким, что

$$\begin{aligned} 2^{k-1} \leq n \leq 2^k - 1 &\Leftrightarrow (k \leq \log_2 n + 1) \& (k \geq \log_2(n + 1)) \\ &\Leftrightarrow k = \lfloor \log_2 n + 1 \rfloor = \lceil \log_2(n + 1) \rceil. \end{aligned}$$

Рассмотрим коды, исправляющие одну ошибку типа замещения в словах длины  $n$ . Выберем натуральное  $k$  таким, что

$$\begin{aligned} 2^{k-1} \leq n \leq 2^k - 1 &\Leftrightarrow (k \leq \log_2 n + 1) \& (k \geq \log_2(n + 1)) \\ &\Leftrightarrow k = \lfloor \log_2 n + 1 \rfloor = \lceil \log_2(n + 1) \rceil. \end{aligned}$$

Разобьем номера всех разрядов исходного слова на  $k$  классов:

$$D_i = \{m \mid m = (m_{k-1} m_{k-2} \dots m_0)_2, m_i = 1\}, 1 \leq m \leq n.$$

## Definition

Кодом Хэмминга порядка  $n$  называется множество наборов  $\tilde{\alpha} = (\alpha_1, \alpha_2, \dots, \alpha_n) \in E_2^k$ , удовлетворяющих системе уравнений (суммы — по модулю 2):

$$\left\{ \begin{array}{lcl} \sum_{j \in D_0} \alpha_j & = & 0 \\ \sum_{j \in D_1} \alpha_j & = & 0 \\ & \dots & \\ \sum_{j \in D_{k-1}} \alpha_j & = & 0 \end{array} \right.$$

## Theorem

Код Хэмминга порядка  $n$  содержит  $2^{n-k}$  наборов, где  $k = \lfloor \log_2 n \rfloor + 1$  и исправляет одну ошибку.

## Theorem

Код Хэмминга порядка  $n$  содержит  $2^{n-k}$  наборов, где  $k = \lfloor \log_2 n \rfloor + 1$  и исправляет одну ошибку.

**Доказательство.** Рассмотрим систему уравнений из определения кода Хэмминга:

$$\left\{ \begin{array}{rcl} \alpha_1 \oplus (\alpha_3 \oplus \dots) & = & 0 \\ \alpha_2 \oplus (\dots) & = & 0 \\ & \dots & \\ \alpha_{2^{k-1}}(\dots) & = & 0 \end{array} \right.$$

Заметим, что  $\alpha_1, \alpha_2, \dots, \alpha_{2^{k-1}}$ , вынесенные нами за скобки, в скобках уже не встречаются. Значит, если значения всех остальных  $\alpha_j$  мы зададим произвольно, то  $\alpha_1, \alpha_2, \dots, \alpha_{2^{k-1}}$  однозначно определятся из системы.

Пусть передавалось кодовое слово  $\tilde{\alpha} = (\alpha_1 \alpha_2 \dots \alpha_n)$  и ошибка произошла в разряде  $\mathbf{d} = (\gamma_{k-1} \gamma_{k-2} \dots \gamma_1 \gamma_0)_2$ . Пусть на выходе получено слово  $\tilde{\beta} = (\beta_1 \beta_2 \dots \beta_n)$ , при этом  $\beta_i = \alpha_i$  при  $i \neq \mathbf{d}$ ,  $\beta_{\mathbf{d}} = \alpha_{\mathbf{d}} \oplus 1$ .



Пусть передавалось кодовое слово  $\tilde{\alpha} = (\alpha_1 \alpha_2 \dots \alpha_n)$  и ошибка произошла в разряде  $\mathbf{d} = (\gamma_{k-1} \gamma_{k-2} \dots \gamma_1 \gamma_0)_2$ . Пусть на выходе получено слово  $\tilde{\beta} = (\beta_1 \beta_2 \dots \beta_n)$ , при этом  $\beta_i = \alpha_i$  при  $i \neq \mathbf{d}$ ,  $\beta_{\mathbf{d}} = \alpha_{\mathbf{d}} \oplus 1$ .

Обозначим  $\delta_0 = \sum_{j \in D_0} \beta_j$ ,  $\delta_1 = \sum_{j \in D_1} \beta_j$ ,  $\dots$ ,  $\delta_{k-1} = \sum_{j \in D_{k-1}} \beta_j$ . Покажем, что  $(\delta_{k-1} \delta_{k-2} \dots \delta_1 \delta_0)_2 = \mathbf{d}$ .

Пусть передавалось кодовое слово  $\tilde{\alpha} = (\alpha_1 \alpha_2 \dots \alpha_n)$  и ошибка произошла в разряде  $\mathbf{d} = (\gamma_{k-1} \gamma_{k-2} \dots \gamma_1 \gamma_0)_2$ . Пусть на выходе получено слово  $\tilde{\beta} = (\beta_1 \beta_2 \dots \beta_n)$ , при этом  $\beta_i = \alpha_i$  при  $i \neq \mathbf{d}$ ,  $\beta_{\mathbf{d}} = \alpha_{\mathbf{d}} \oplus 1$ .

Обозначим  $\delta_0 = \sum_{j \in D_0} \beta_j, \delta_1 = \sum_{j \in D_1} \beta_j, \dots, \delta_{k-1} = \sum_{j \in D_{k-1}} \beta_j$ . Покажем, что  $(\delta_{k-1} \delta_{k-2} \dots \delta_1 \delta_0)_2 = \mathbf{d}$ .

Пусть  $\gamma_i = 0 \Rightarrow \mathbf{d} \notin D_i$ , тогда  $\sum_{j \in D_i} \beta_j = \sum_{j \in D_i} \alpha_j$ , значит,  $\delta_i = 0, \delta_i = \gamma_i$ .

Пусть передавалось кодовое слово  $\tilde{\alpha} = (\alpha_1 \alpha_2 \dots \alpha_n)$  и ошибка произошла в разряде  $\mathbf{d} = (\gamma_{k-1} \gamma_{k-2} \dots \gamma_1 \gamma_0)_2$ . Пусть на выходе получено слово  $\tilde{\beta} = (\beta_1 \beta_2 \dots \beta_n)$ , при этом  $\beta_i = \alpha_i$  при  $i \neq \mathbf{d}$ ,  $\beta_{\mathbf{d}} = \alpha_{\mathbf{d}} \oplus 1$ .

Обозначим  $\delta_0 = \sum_{j \in D_0} \beta_j$ ,  $\delta_1 = \sum_{j \in D_1} \beta_j$ ,  $\dots$ ,  $\delta_{k-1} = \sum_{j \in D_{k-1}} \beta_j$ . Покажем, что  $(\delta_{k-1} \delta_{k-2} \dots \delta_1 \delta_0)_2 = \mathbf{d}$ .

Пусть  $\gamma_i = 0 \Rightarrow \mathbf{d} \notin D_i$ , тогда  $\sum_{j \in D_i} \beta_j = \sum_{j \in D_i} \alpha_j$ , значит,  $\delta_i = 0$ ,  $\delta_i = \gamma_i$ .

Пусть теперь  $\gamma_i = 1$ ,  $\mathbf{d} \in D_i$ . Тогда

$$\sum_{j \in D_i} \beta_j = \sum_{j \in D_i} \alpha_j \oplus 1 = 1 \Rightarrow \delta_i = 1 \Rightarrow \delta_i = \gamma_i.$$

□

## Theorem

$$\frac{2^n}{2n} \leq M_1(n) \leq \frac{2^n}{n+1}.$$

**Доказательство.** По одной из предыдущих теорем:

$\frac{2^n}{S_{2r}(n)} \leq M_r(n) \leq \frac{2^n}{S_r(n)}$ . Тогда правое неравенство явно следует из  $S_1(n) = n + 1$ .

## Theorem

$$\frac{2^n}{2n} \leq M_1(n) \leq \frac{2^n}{n+1}.$$

**Доказательство.** По одной из предыдущих теорем:  
 $\frac{2^n}{S_{2r}(n)} \leq M_r(n) \leq \frac{2^n}{S_r(n)}$ . Тогда правое неравенство явно следует из  $S_1(n) = n + 1$ .

В коде, исправляющем одну ошибку, различных слов ровно  $2^{n-k} = m$ . Поскольку  $k = \lfloor \log_2 n \rfloor + 1$ , тогда

$$k \leq \log_2 n + 1 \Rightarrow m \geq 2^{n-\log_2 n-1} = \frac{2^n}{2n} \Rightarrow M_1(n) \geq m \geq \frac{2^n}{2n}.$$

□